

FIT5196-S2-2026 小组评估第一阶段（15%）

这是一个小组评估，占你总成绩的**15%**。

截止日期：23:55，星期三，第7周（2026年9月9日）

本规范定义了评估工作、共享转换规则、提交要求、快速入门指南、检查清单和术语表。单独的评分标准定义了如何评估证据。您分配的数据包中的 `public_data_dictionary.csv` 定义了所需的输出表粒度、字段、字段顺序、数据类型、可空性和比较规则。包内的 `README.md` 定义了包特定的源规范。

1. 场景

您的团队收到了来自墨尔本一家科技零售商使用的两个不同操作系统的历史导出文件。一个是 JSON 格式，另一个是 XML 格式。它们共同描述了客户、产品、交易、配送和长期客户评论。

这些系统以不同的方式表示相同的信息。它们使用不同的嵌套方式、字段名、数据格式和文本规范。记录可能在两个来源内部或跨来源重叠。您的团队必须构建一个可重复的工作流程，该工作流程解析来源、协调重叠的记录、生成六个可用于分析的关系表、验证结果并进行有针对性的探索性数据分析（EDA）。

这是FIT5196评估项目的第一个阶段。后续的评估阶段将使用相关的当期数据。教学团队将提供经过认证的数据，用于高风险的下游评估，以便A1错误不会在后期自动再次被扣分。您仍然应该保留您的代码、决策和输出，因为您的推理可能会为后续工作提供参考。

2. 评估的学习成果

通过完成A1，你的小组应该展示出它能够：

1. 使用适当的结构化解析器解析和检查半结构化JSON和XML；
2. 将嵌套和重复的来源记录映射到具有定义粒度和关系的关系表；
3. 标准化标识符、日期、时间戳、布尔值、数值和叙述性字段；
4. 使用正则表达式进行有界文本清理和提取任务；
5. 在创建特定用途的分析字段时，保留有效的多语言 Unicode 文本拉丁字母脚本；
6. 调整重复和重叠的记录，避免重复计数；

7. 验证键、关系、算术和转换行为；
8. 进行可靠的单元变量、双变量和多变量EDA；以及
9. 将EDA证据转化为可行的机器学习问题，同时识别泄露、评估和部署风险。

在A1中不需要进行模型训练。

3. 提供的文件

每个小组将获得一个分配的存档，命名为GroupNNN_A1.zip，其中NNN是三位数的小组编号。它包含：

- A1_manifest.json
- README.md
- public_data_dictionary.csv
- raw_input/
 - GroupNNN_commerce.json
 - GroupNNN_operations.xml

教学团队还提供评分标准和一个 templates/ 文件夹：

- 一个1_源_到_目标_映射_模板.csv；
- 一个1_解决方案_模板.ipynb；
- 一个1_EDA_模板.ipynb；
- A1_公共_文本_测试_案例.csv；和
- 一个1_AI_使用_声明_模板.docx。

源文件包含数百个客户和产品记录，以及数千笔交易、交付和评价记录。这些是规模指标，不是预期的干净行数。教学团队不会发布规范行数、重叠计数、重复位置或预期输出值。

仅使用分配给您小组的数据。部分源内容可能跨小组共享，但每个包都根据其自身的认证参考进行评估。开始前，请核实存档名称、源文件名和公共清单中的组号。

4. 必要工作

任务 1：解析和分析源

使用 JSON 解析器处理 JSON 文件，使用 XML 解析器处理 XML 文件。不要用正则表达式将这两种结构化文档当作纯文本解析。

你的笔记本和源到目标映射必须显示你调查了以下内容。报告应仅总结材料决策：

- 主要对象、嵌套数组、重复的 XML 元素和特定源表示；
- 候选主键和外键；
- 每个源集合的粒度；
- 日期、时间戳、布尔值、货币、百分比和缺失值格式；
- 出现在一个或两个源中的字段；
- 源内的重复记录和跨源的重复记录；
- 转换前需要假设。

完成提供的源到目标映射模板。其目标字段已预填，但你必须调查并输入每个所需输出字段的适用 JSON 和/或 XML 路径、派生或规范化、重叠/冲突规则和笔记本证据。源路径故意未预填，因为分配的包中两个源布局不同。映射必须描述你的方法，而不是列出每个单个数据行

使用 JSON、XML、两者或派生完成六个空白列，用于源_格式；结构路径用于 json_源_路径和 xml_源_路径；以及转换_或_派生、重叠_或_冲突_规则和笔记本_证据。使用 | 分隔多个输入字段。解决方案笔记本模板解释了每一列，并包含虚构的示例。

任务 2：生成六个标准化的关系表

生成这六个提交的数据表：

1. 订单
2. 订单 _商品
3. 客户
4. 配送
5. 产品
6. 产品_评价

使用这些文件名：

- GroupNNN_订单_标准化.csv
- GroupNNN_order_items_标准ised.csv
- GroupNNN_客户_标准化.csv
- GroupNNN_配送_标准化.csv
- GroupNNN_产品_标准化.csv
- GroupNNN_产品_评价_标准化.csv

所需的谷物和主键是：

表	谷物	主键
订单	每个规范订单一行	订单ID_
按订单项排序_	每个订单项一行	订单项ID_ _
客户	每个客户一行	客户ID_
配送	每行一个完成的订单 配送	配送_id
产品	每行一个产品	产品_ID
产品_评价	每个规范产品评价一行	评价ID_

必须的外键关系是：

子字段	父字段
订单.客户ID_	客户.客户ID_
订单项.订单ID_ _	订单.订单ID_
订单_项.产品_ID	产品产品_id
配送订单 _id	订单订单 _id
产品_评价订单_id	订单订单 id_
产品_评价订单_商品_id	订单项.订单项ID_ _ _
产品_评论.产品_ID	产品.产品_ID
产品_评论.客户_ID	客户.客户ID_

所有列出的主键和外键都是必需且不能为空。

对于每个文件，请遵循 public_data_dictionary.csv 以获取表格谷物、字段名称、字段顺序、数据类型、空值性和数值比较容差。不要向提交的六个 CSV 文件中添加辅助或仅用于 EDA 的列。辅助表和列可以在您的代码中创建。

您的流程必须，在适用的情况下：

- 展平嵌套数组而不改变预期的实体粒度；
- 保留有效的“一对多”关系，而不是将所有信息强制填入一个扁平化表格；

- 规范化稳定标识符，无需创建新的实体标识；
- 保留标识符的前导零，标识符或结构化类别不转换为小写，除非特定字段规则要求；
- 标准化日期为 YYYY-MM-DD；
- 标准化时间戳为 YYYY-MM-DD HH:MM:SS；
- 标准化布尔值为 True 或 False；
- 在数值转换前移除货币标签和千位分隔符；
- 以目标字段所需的数值百分比点表示百分比；
- 根据公共词典导出所需字段，并在适当情况下进行行和顺序算术运算；
- 对于规定的缺失字符串结果，使用字面量字符串 “NaN” 而不是空字符串；
- 使用稳定的业务键和字段级比较，在来源内部和跨来源之间协调记录；以及
- 在相同输入上重新运行时，产生确定性输出。

对于来源协调，首先规范化可比较字段，然后使用表主键比较记录，并保留每个键的一个规范行。在评估数据中匹配的记录在发布后的规范化规则下保持一致。因此，正确规范化的重复记录不需要任意的 JSON-over-XML 或 XML-over-JSON 优先级规则。如果您的代码检测到同一目标字段和键的不同非缺失值，请在验证中记录冲突，而不是静默地选择其中一个。

对于指定的缺失字符串输出，请写入三个字面字符 NaN。这不是 Python 的 None、NumPy/pandas 的缺失值或空字段。在读取提交的 CSV 文件进行验证时，请使用 `pandas.read_csv(path, keep_default_na=False)`，以便保留哨兵值。不要将字符串 NaN 放在必填的数字或布尔字段中。

对于发布的订单运算，请使用以下序列：

1. 计算 `每行收入` 为 `数量 * 单价`，结果保留两位小数；
2. 计算 `订单价格` 为所有四舍五入后的行收入之和，结果保留两位小数；
3. 将产品价格视为含 GST，并在优惠券折扣前计算含税金额，即 `订单_价格 / 11`，结果保留两位小数；
4. 对 `订单_价格` 应用 `优惠券_折扣`；
5. 添加 `配送_费用`；和
6. 将产生的 `订单_总额` 四舍五入到两位小数。

`税_金额` 单独报告，不再添加到 `订单_总额` 中。对已发布的货币字段使用绝对比较容差 0.01。

不要硬编码规范行数、单个预期值或已知重复标识符的列表。正确的管道必须从分配的源文件中推导其输出。

任务 3：正则表达式和多语言文本预处理

正则表达式用于有界叙事清理和提取，必须在使用结构化解析器获取相关 JSON 值或 XML 元素后应用。

原始叙事字段可能包含 HTML 实体、HTML/XML 样式的标签、URL、表情符号、混合空白、社交标记和括号内的系统元数据。对于本次评估，可移除的括号和社交标记模式完整集为：

[SYSTEM]

[目录]

[已验证_购买]

[来源：...]

[评分：n/5]

#已验证买家

@店铺_支持

应用此文本处理顺序：

1. 使用结构化JSON/XML解析器获取值；
2. 从原始值中提取任何所需的订单、SKU或促销参考；
3. 解码 HTML 实体并应用 Unicode NFC 规范；
4. 移除 HTML/XML 类似标签，同时保留可读内容；
5. 移除列出的系统/来源/评分/社交标记、URL 和表情符号；
6. 移除完整的评论引用包装器，包括 Reference:、订单引用、分隔符、SKU: 和 SKU；
7. 移除 PROMO: 及其代码；
8. 合并空格、制表符和换行符，修剪，并将指定的清理后的叙述转换为小写；和
9. 如果没有人类可读的文本剩余，则返回字面量字符串 NaN。

使用正则表达式处理有界模式，例如标签、标记、URL、空白字符和业务参考提取。标准库工具如 `html` 和 `unicodedata` 可用于实体解码、Unicode 规范化和脚本分类。不要使用正则表达式来重建 JSON 或 XML 结构。

提取这些嵌入的业务参考（当存在时）：

参考	公共格式	缺失时输出
顺序参考	HORD或CORD后跟恰好六位数字	NaN
产品SKU	SKU-后跟一个或多个ASCII字母或数字	NaN
促销代码	B1SAVE-至B5SAVE- , 后跟恰好两个数字	NaN

以大写形式返回提取的参考。边界处理很重要：一个更长、格式错误或接近匹配嵌入的不能被视为有效参考。

多语言评审合同

评审内容主要为英语，但也包含较小的多语言部分。这两个评审输出有不同的用途：

- `review_body_clean` 必须保留有效的多语言 UTF-8 字母。它不能仅仅因为包含非拉丁文字就擦除一个有效的评审。
- `review_body_latin_analysis` 是一个独立的派生字段。它保留拉丁字母文字，包括欧洲变音符号，以及适用的数字和标点符号，同时移除非拉丁字母。如果没有拉丁字母剩余，返回 NaN。
- `contains_non_latin_script` 是基于清理后的多语言评审是否包含任何拉丁字母文字以外的字母。非 ASCII 字符不自动属于非拉丁文字。

不要从拉丁分析字段推断语言_代码。使用并协调为此属性提供的结构化源证据。

从 `review_body_clean` 构建 `review_body_latin_` 分析，而不是从嘈杂的原始 `review`。按以下方式导出 `review` 指标：

`review_长度_字符 = review_主体_干净`

`review_词_数 = review_正文_清理`

当 `review_body_clean` 是字面 NaN 时，保留已发布的哨兵行为，而不是将三个字母计为普通的 `review`。

使用匹配、不匹配、缺失、多语言和近似匹配示例来记录和测试您的文本函数。运行提供的公共文本用例并添加您自己的测试。在使用 `pandas` 时，用 `keep_default_na=False` 加载用例。教学团队可能会根据本规范对提交的函数在私有边缘用例上进行测试。私有测试将不需要在已发布的规则中缺失的行为。

将以下六个函数放在 `GroupNNN_text_functions.py` 中，以便在不修改您的笔记本的情况下测试已发布的接口：

```
def clean_narrative_text(value):  
    """接受 None 或字符串；返回清理后的文本或字符串 'NaN'。"""
```

```
def extract_order_reference(value):  
    """接受 None 或字符串；返回大写的参考或 'NaN'。"""
```

```
def extract_产品_sku(value):  
    """接受 None 或字符串；返回大写的 SKU 或 'NaN'。"""
```

```
def extract_促销_码(value):  
    """接受 None 或字符串；返回大写代码或 'NaN'。"""
```

```
def build_拉丁_分析(value):  
    """接受清理后的多语言文本；返回拉丁分析或 'NaN'。"""
```

```
def contains_非_拉丁_文字(value):  
    """接受清理后的多语言文本；返回一个 Python 布尔值。"""
```

函数名称、参数数量和返回契约是固定的。您的实现不是。在这些函数内部不要执行文件 I/O、网络访问或特定行查找。

任务 4：验证处理后的数据

在解决方案笔记本的验证注册部分提供可执行的验证检查。为每个检查分配一个稳定的 ID，例如 VAL-PK-01，以便报告可以引用它而无需复制完整的检查证据。对于每个检查，显示观察结果、PASS/FAIL 状态和解决方案或解释。笔记本模板还提醒您区分字面量字符串 NaN、空字符串和 Python/pandas 缺失值。至少应涵盖：

- 必需的表和列存在；
- 目标数据类型和缺失值表示；
- 主键完整性和唯一性；
- 六个表之间的外键完整性；
- 允许的分类值和合理的数值范围；
- 主要转换前后的源覆盖率与行数；
- 源内和跨源重叠的处理；
- 按订单项行对订单价格进行核对；
- 按价格、折扣和配送字段对订单总额进行核对，并单独检查税额是否为包含的 GST 部分且未被重复添加；
- 在适用情况下，订单、发货、承诺、交付和评审时间戳之间的有效时间顺序；
- 提取的订单/SKU/促销引用；以及
- 多语言保护和非拉丁脚本指示符。

对浮点数或货币检查使用明确的容差。验证结果必须显示检查、观察结果和通过/失败状态。不要编写仅确认硬编码预期计数的断言。

发现并报告真实的来源或合同问题是一项专业的数据工作。当证据和拟议的处理方案具有充分理由时，报告的失败情况并不自动意味着错误。不要编造一个值，仅仅为了让一个断言成立。

任务 5：执行聚焦式 EDA

对关系输出进行单变量、双变量和多变量分析。自动生成的配置转储本身并不能满足这项任务。

你的报告必须包含 6-8 个清晰标注的评估可视化图表。该集合必须至少包含来自以下六个类别中的每个类别的一项调查：

1. 单变量分布或组成；
2. 双变量关系或分组比较；
3. 多元或分段关系；
4. 时间模式；
5. 审核或文本行为，例如语言、长度、评分或有用性；和
6. 与订单、客户、产品或评论相关的交付或运营绩效特征。

总体而言，评估的可视化必须使用至少六张输出表中的四张证据，并包含至少两项正确连接相关表的分析。当分析问题确实如此时，一个可视化可能满足多个类别。一套协调的子图在面板回答一个共同问题时算作一个可视化。将评估的项目标记为图1、图2等。只有前八个清晰标记的评估可视化会被评分。

对于每个评估的可视化：

1. 说明分析问题；
2. 说明观测单位和分母；
3. 确定使用的表格和连接键；
4. 选择适合变量和比较的图表；
5. 提供可读的标题、坐标轴、图例和单位；以及
6. 解释结果和材料限制。

在处理连接时要特别小心。连接多个一对多表可能会使行数成倍增加，并导致收入、订单或客户指标虚高。应在其预期粒度上计算每个指标，并展示防止意外重复计算的检查。

任务6：展示发现和未来的机器学习问题

展示正好十个编号的、有证据支持的发现。每个发现必须引用一个评估的数值或报告的统计数据，并解释：

- 观察到了什么以及分析的粒度；
- 幅度、分母或样本量；
- 为什么这在零售环境中可能很重要；
- 一个合理的替代解释或不确定性；以及
- 一个相称的影响、下一步的调查或建议。

一项发现表明，若一个明显的关系较弱、不确定或不具有决策相关性，并且有证据支持，则该发现仍可能是高质量的。在没有可辩护的设计的情况下，不要从观察性关联中声称因果关系。

请提出五个编号的机器学习问题，这些问题需基于你的探索性数据分析（EDA）。这五个问题必须涵盖至少两种不同的问题类型，例如分类、回归、聚类、异常检测或预测。对于每个问题，请指定：

- 相关的业务决策或用例；
- 预测或分析单元；
- 建议的目标或无监督目标。
- 决策时可供使用的候选预测变量；
- 适当的验证拆分；
- 至少一个评估指标；以及
- 可能存在目标泄漏、时间序列泄漏、公平性或部署风险。

问题必须在使用的数据类型上可行。使用提供的EDA笔记本模板，每道问题目标为80-120字或一个紧凑表格。不要在A1中训练或比较模型。

5. 可重复性和代码要求

提交 Python 代码，用于重现分配的原始包中的所有六个 CSV 文件和验证结果，并附带一个 EDA 笔记本，用于重现从这六个 CSV 文件中评估的所有可视化结果和报告的统计数据。

提交的笔记本必须：

- 包含一个清晰标记的配置单元格；解决方案笔记本必须定义 GROUP_ID、INPUT_DIR 和 OUTPUT_DIR；
- 使用相对路径或可配置路径，而不是学生的绝对路径；
- 使用 Restart and Run All 从一个全新的内核运行；
- 包含用于审查分析所需的输出；
- 避免手动编辑生成的 CSV 文件；
- 避免使用硬编码的规范答案；并且
- 使用向量化或其他合理的方法来处理提供的规模。

解决方案笔记本必须包含完整的转换和验证工作流程。EDA 笔记本必须加载提交的六个 CSV 文件，并重现报告的图表和统计数据，而无需重新运行不同的隐藏清洗管道。提交的 GroupNNN_solution.py 导出必须反映解决方案笔记本。可以导入 GroupNNN_text_functions.py 中的所需函数；函数无需重复。在 requirements.txt 中列出任何非标准依赖项和版本。评估的工作流程必须在离线状态下运行：它不能依赖于实时 AI 服务、外部 API、网络下载、私有账户、API 密钥或未提交的本地文件。

修复路径、安装未记录的软件包、重写学生代码或手动完成失败的转换，都不需要标记。当笔记本无法执行时，可用的输出和记录的方法可能根据评分标准提供部分证据。

6. EDA报告要求

提交 GroupNNN_EDA.pdf，最多10页，从引言到结论。封面、目录和参考文献不计入页数限制。附录只有在规格明确要求材料或主报告直接引用其作为验证证据时才会被评估。

使用清晰的格式，例如：

1. 问题背景和数据范围；
2. 数据准备保证；
3. 6-8个评估可视化；
4. 10个编号发现；
5. 5个编号的机器学习问题；
6. 限制；以及
7. 结论。

数据准备保证部分应传达大约3-5个实质性转换决策和4-6个实质性验证结果，在有用时引用稳定的映射和验证ID。单独的映射CSV文件是完整的字段血缘记录，解决方案笔记本是完整的可执行检查记录。报告中不要重复任何完整工件。

代码列表不应出现在报告中，除非需要简短的表达来解释一个评估的决策。表格和图表必须在100%缩放下保持可读性。使用一致的引用风格来引用外部事实、代码、数据和想法。

7. 提交要求

将这两个文件提交到A1 Moodle作业：

- GroupNNN_A1_提交.zip

● GroupNNN_EDA.pdf

ZIP 文件必须包含：

- GroupNNN_解决方案.ipynb
- GroupNNN_solution.py
- GroupNNN_EDA.ipynb
- GroupNNN_文本_函数.py
- GroupNNN_source_to_target_映射.csv
- GroupNNN_AI_声明.pdf
- requirements.txt # 仅用于非标准依赖
- AI_记录/ # 当使用对话式AI时需要
 - GroupNNN_AI_索引.pdf
 - 完成_chat_导出...
- outputs/
 - GroupNNN_订单_标准化.csv
 - GroupNNN_订单_商品_标准化.csv
 - GroupNNN_客户_标准化.csv
 - GroupNNN_配送_标准化.csv
 - GroupNNN_产品_标准化.csv
 - GroupNNN_产品_评价_标准化.csv

不要提交教学团队提供的原始 JSON/XML 文件。不要将 EDA PDF 放在 ZIP 压缩包内。上传前请遵循附录 A 中的清单。每个小组成员都有责任确认 Moodle 提交收据中显示的是正确的组文件。

8. 生成式 AI 使用

在准备 A1 时，可以使用生成式 AI 工具，但需遵守大学和课程的政策。小组对所有提交的转换、测试、图表、引用、陈述和文件都负有责任。

每个小组都必须提交签署的AI使用声明。如果任何成员使用了对话式AI工具，该小组还必须提交 AI_records/中所有与作业相关的对话的完整直接导出，并附带一个记录目的、提交位置和独立验证的英文索引。不要选择性地缩短作业对话。使用单独的评估特定聊天，以便无关的私人材料不会被混入记录中。如果工具没有导出功能，将完整对话打印为PDF或HTML。没有对话历史的内联代码补全仍需声明，但不需要虚构的聊天导出。遵循模板/A1_AI_use_declaration_template.docx。

附录 A：提交清单

重启并运行最终笔记本后，使用此清单。

分组和打包

- ☐ 分配的存档、清单和原始文件名都显示相同的 GroupNNN 标识符。
- ☐ 每个提交的文件名都使用该确切的三个数字标识符。
- ☐ 每个小组成员都已审查最终的 Moodle 提交收据。

可重复性

- ☐ GroupNNN_solution.ipynb 和 GroupNNN_EDA.ipynb 都使用 Restart and Run All 来运行。
- ☐ 该笔记本具有可配置的 GROUP_ID、INPUT_DIR 和 OUTPUT_DIR 值，并且没有学生特定的绝对路径。
- ☐ GroupNNN_solution.py 反映了最终的笔记本工作流程。
- ☐ GroupNNN_text_functions.py 暴露了所有六个必需的函数，并且不执行文件 I/O 或网络访问。
- ☐ 解决方案工作流程重新创建了 CSV 文件和检查；EDA 工作流程重新创建了图表和报告的统计数据，无需手动编辑或实时服务。
- ☐ 如果需要非标准依赖项，则会包含 requirements.txt。

数据产品与保证

- ☐ 所有六个必需的 CSV 文件都在 outputs/ 目录内。
- ☐ 文件名、列、顺序、数据类型和粒度与公共数据字典一致。
- ☐ 主键、外键、源覆盖率、计算和时效性均经过检查。
- ☐ GST、折扣、配送和总计遵循已发布的计算顺序。
- ☐ 重复对账采用数据驱动而非硬编码的方式。
- ☐ 该映射使用稳定的 MAP-... ID 完成每个预填充的目标行。
- ☐ 解决方案笔记本记录稳定的 VAL-... ID，观察到的结果，status，证据和解释。

文本处理

- ☐ JSON 和 XML 在应用正则表达式到文本之前被结构化解析。
- ☐ 标签、实体、标记、URL、社交令牌、表情符号和空白符遵循已发布的规则。
- ☐ 订单、SKU 和促销引用有边界和近似匹配测试。
- ☐ review_body_clean 保留有效的多语言文本。
- ☐ 单独的拉丁分析字段保留了拉丁变音符号。
- ☐ 所有提供的公共文本案例均已运行，并展示了附加测试。

报告

- ☐ GroupNNN_EDA.pdf 最多不超过 10 页评估内容。
- ☐ 其中 6 至 8 个图表被标记为评估过的可视化内容。
- ☐ 该集合涵盖了所有六个分析类别，至少包含四个表格，以及至少两个正确的关联分析。
- ☐ 观察单元、分母和连接乘法检查都很清晰。
- ☐ 正好有 10 个基于证据的发现和 5 个机器学习问题被编号。
- ☐ 局限性、不确定性、泄漏风险和外部引用都很明确。

人工智能与最终存档

- ☐ GroupNNN_人工智能_声明.pdf 已由所有成员签署。
- ☐ 当使用对话式人工智能时，AI_记录/ 包含索引和完整的任务相关导出。
- ☐ 即使没有聊天导出，也会声明内联完成。
- ☐ 材料人工智能生成的代码和声明具有独立的检查。
- ☐ 原始教学数据未包含在提交中。
- ☐ 最终上传的文件正好是 GroupNNN_A1_submission.zip 和 GroupNNN_EDA.pdf。

附录 B：术语表

Term	A1 中的含义
规范行	在重叠后，代表一个业务实体的单个保留行经过对账
数据粒度	一行代表什么，例如一个订单或一个订单项
分母	用于计算比率或比例的总人口或比例
确定性	相同的输入和代码每次都会产生相同的输出
外键	一个字段，它引用另一个表中的主键
血缘关系	一个输出字段来自哪里以及它是如何转换的

Term	A1中的含义
近似匹配	看似有效引用但未满足必要边界的文本
观测单元	分析中测量的实体，例如订单或评论
主键	用于唯一标识表中每一行的字段或字段在表粒度上
关系连接	通过相关关键字段组合表
源到目标映射	每个输出字段的源记录和转换
目标泄漏	使用在需要做出预测时不可用的信息
时间泄漏	使用未来信息来预测一个较早的事件
Unicode	一种代表不同语言书写系统和符号的标准
矢量化操作	将操作应用于列/数组，而不是逐行循环